AI AGENTS / DECISION MAKING

THE VANISHING HOUR.

Kann ein kleines Decision Model ein LLM bei Agentenentscheidungen ersetzen?

GPT-4.1

KEV 0.8B

4 SPIELMODI

PERSONAL AI ENGINEERING EXPERIMENT

Eine Stunde ist verschwunden.

Ein kleines Mystery-Spiel wird zum Testlabor für sequenzielle KI-Entscheidungen.

00:00 → 01:00

Hogwarts verliert eine Stunde. Der Chronos-Kristall ist verschwunden.

DER AUFTRAG

01 Wer ist verantwortlich?

02 Was hat die Störung ausgelöst?

03 Wie wird die Stunde wiederhergestellt?

Jede Entscheidung hat einen Preis.

Begrenztes Budget, verdeckte Wahrheit und Aktionen, die erst nach neuen Hinweisen freigeschaltet werden.

16

Budgetpunkte zum Start

13

Untersuchungsaktionen

3

Ziele für einen gültigen Abschluss

BEISPIEL EINER SPUR

Uhr analysieren → **Runencode entdecken** → **Runen entziffern**

Dasselbe Spiel. Vier Arten zu entscheiden.

Alle Modi nutzen dieselbe Spielwelt, dieselben Werkzeuge und dasselbe Ermittlungsbudget.

01 / HUMAN

Selbst spielen

Manuelle Auswahl jeder Aktion – der Mensch trifft die nächste Entscheidung.

02 / RULES

Deterministisch

Feste Prioritätenliste ohne KI-Inferenz oder flexible Planung.

03 / LLM

GPT-4.1

Azure LLM interpretiert die bisherigen Beweise und entscheidet den nächsten Schritt.

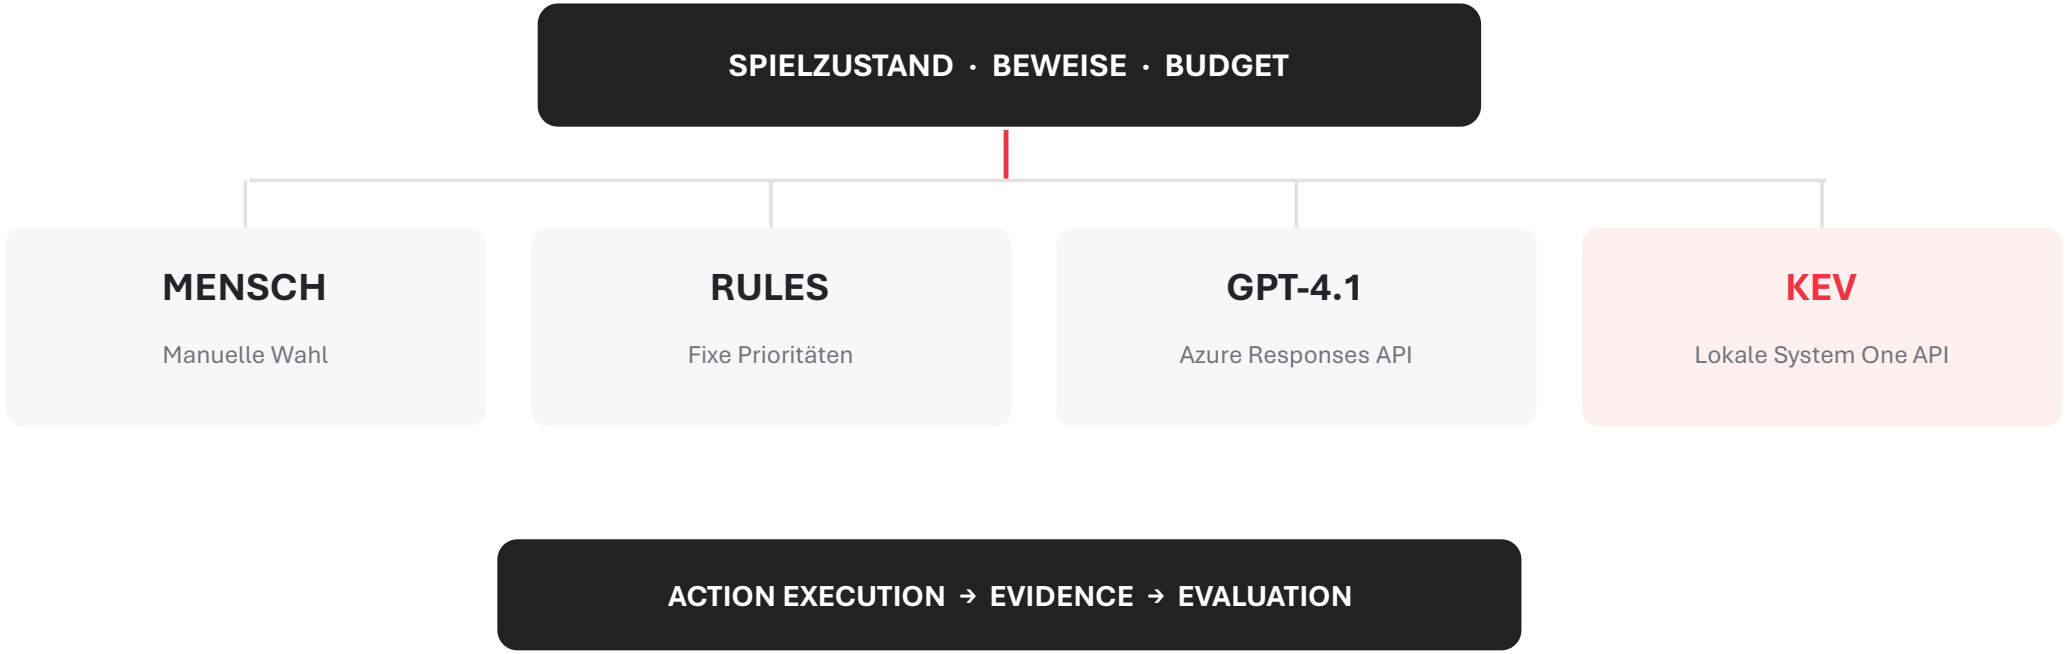
04 / LOCAL

Kev-0.8B

Lokaler Choice Router bewertet verfügbare Aktionen; GPT-4.1 schreibt den Abschlussbericht.

Ein gemeinsamer Engine-Kern.

Nur die Entscheidungsinstanz wird ausgetauscht.



Reasoning vs. Choice Scoring

Die zentrale Frage: Wer verfolgt die wichtigste Spur mit möglichst wenig Umwegen?

GPT-4.1

Interpretiert Beobachtungen, wägt Optionen ab und formuliert eine begründete Aktionsentscheidung.

Azure-Inferenz

KEV-0.8B

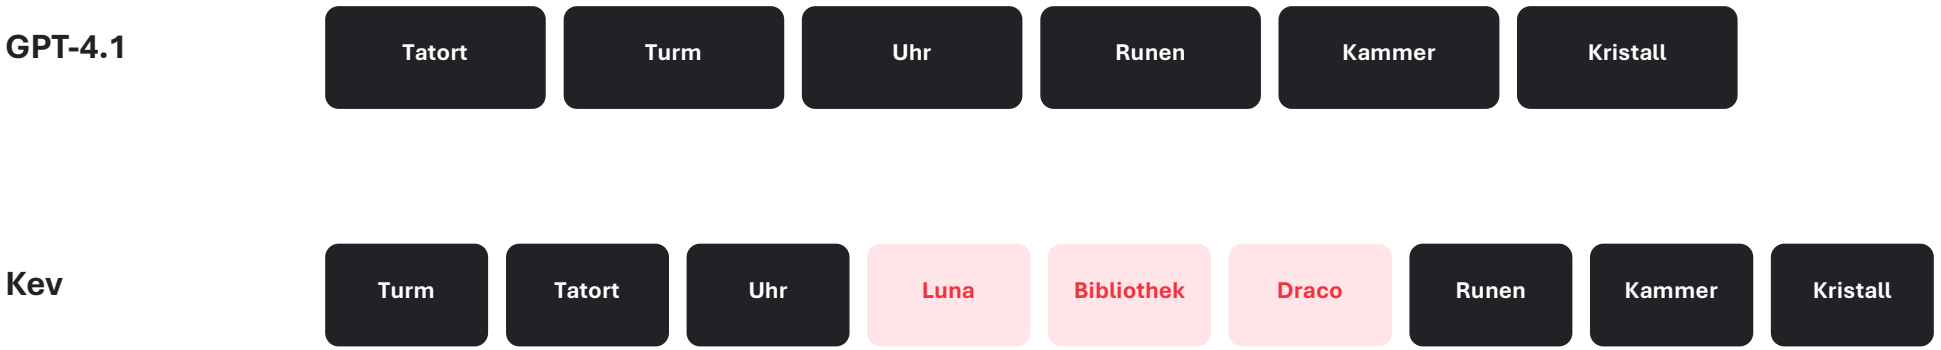
Bewertet die angebotenen Action Candidates über eine lokale Choice-API – ohne frei generierten Ermittlungsplan.

Lokale Inferenz

Bei Kev erstellt GPT-4.1 weiterhin den finalen Bericht.

Die gleiche Lösung. Unterschiedliche Umwege.

Beide Modelle lösen den Fall; Kev benötigt drei zusätzliche Ermittlungen.



6 zusätzliche Budgetpunkte durch Luna, Bibliothek und Draco.

Schneller entscheiden heißt nicht schneller lösen.

Ein konkreter Run aus der Demo · gleiche Fallvariante und gleiches Startbudget.

METRIK	GPT-4.1	KEV + GPT-4.1
Fall gelöst	**JA**	**JA**
Ermittlungsaktionen	**6**	**9**
Budgetverbrauch	**10 / 16**	**16 / 16**
Gesamtdauer	**24,81 s**	**25,97 s**
Azure-Tokens	**5.567**	**854**
Routing-Modellzeit*	**15,70 s**	**1,83 s**

* Ohne finalen Azure-Abschluss; Kev-Tokens werden lokal berechnet. Modellkosten nicht vollständig bewertet.

LESS LATENCY.
NOT ALWAYS
BETTER DECISIONS.

GPT-4.1

Kürzerer Ermittlungsweg

KEV

Extrem schnelle lokale Entscheidungen

Die Qualität der nächsten Aktion entscheidet über die Effizienz des gesamten Agenten.

09 / FAZIT

Decision Intelligence ist mehr als Modellgröße.

Ein persönliches Experiment über die Grenzen lokaler Choice Models.

01 / QUALITY

Planung zählt.

Ein schneller Router spart wenig, wenn er zu viele zusätzliche Aktionen benötigt.

02 / COST

Lokal ≠ kostenlos.

Kev spart Cloud-Tokens, aber GPU-Betrieb und zusätzliche Schritte gehören zur Gesamtbilanz.

03 / NEXT

Besser evaluieren.

Weitere Fälle mit unterschiedlichen Lösungswegen und ein kleiner lokaler Reasoning-Router als nächster Vergleich.

Was zählt bei Agenten mehr: Routing-Latenz oder die Qualität der Aktionsfolge?